Дополнение к ДЗ3. CSV и Parquet

Вдовина Анастасия Романовна, ИИИ-3-ИнжДан-1-3. Вариант 7 (Go).

1. Что сравнила

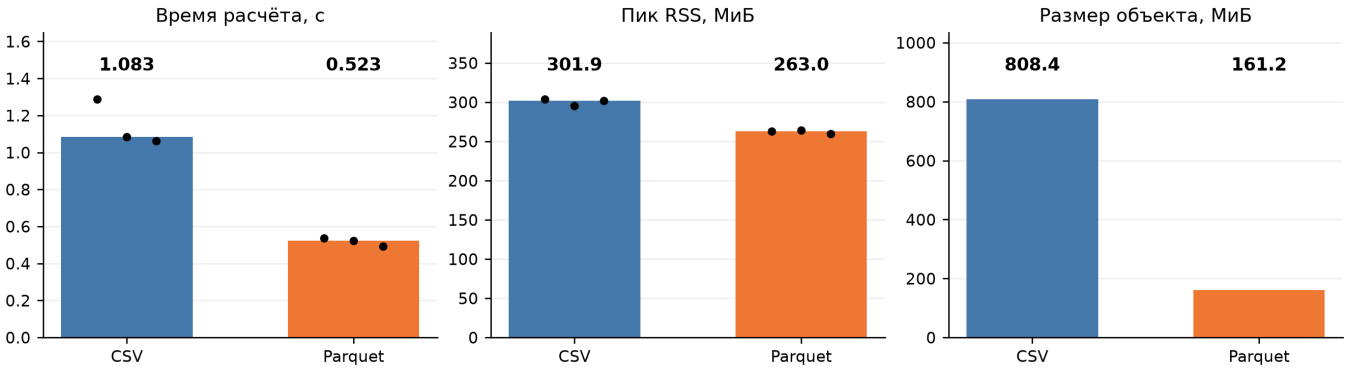
Сохранила весь исходный CSV в Parquet со сжатием ZSTD в том же RustFS, бакете hh-lake. Предварительно вакансии не отбирала: в обоих форматах 229 388 строк и 23 колонки. Типы полей оставила VARCHAR, как при чтении CSV в основной работе.

```
COPY (SELECT * FROM read_csv(
  's3://hh-lake/raw/it_vacancies_2024.csv',
  header=true, delim=',', all_varchar=true))
TO 's3://hh-lake/derived/it_vacancies_2024_trial3.parquet'
(FORMAT PARQUET, COMPRESSION ZSTD, ROW_GROUP_SIZE 122880);
```

Сверила схему и все строки через EXCEPT ALL в обе стороны — расхождений 0. Затем выполнила тот же SQL-фильтр Go и подсчёт навыков, пар и троек. Во всех шести запусках выбраны 3 123 вакансии; все 969, 13 552 и 89 260 частот совпали с MapReduce из основной работы.

2. Три попытки для каждого формата

Формат	Попытка	Время, с	Пик RSS, МиБ
CSV	1	1.288	303.8
Parquet	1	0.535	263.0
Parquet	2	0.523	264.1
CSV	2	1.083	295.0
CSV	3	1.062	301.9
Parquet	3	0.494	259.3



Столбцы — медианы трёх попыток; точки — отдельные замеры. Размер показан для одного объекта.

По медианам время уменьшилось с 1.083 до 0.523 с, ускорение — 2.07 раза. Пик RSS снизился с 301.9 до 263.0 МиБ (12.9%). Размер объекта — с 808.4 до 161.2 МиБ, в 5.01 раза.

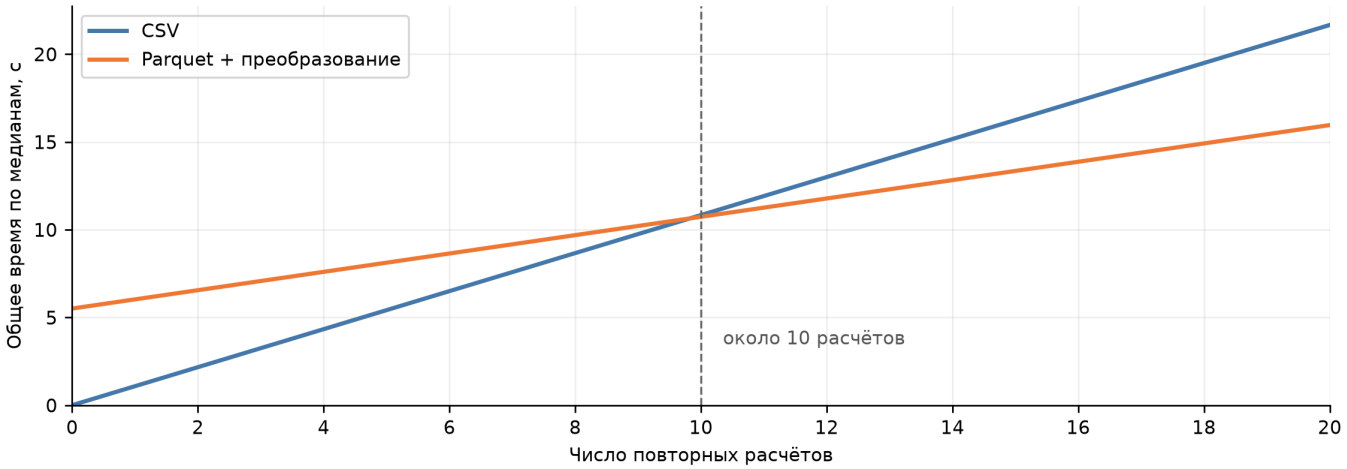
Parquet позволяет читать нужные колонки отдельно; длинное description для подсчёта не требуется. Здесь сравнивается весь переход на Parquet + ZSTD. Отдельный вклад сжатия и чтения колонок не измеряла. Размеры объектов не означают объём фактически прочитанных по сети байтов.

3. Когда окупается преобразование

Само преобразование CSV → Parquet тоже требует времени и памяти. Повторила его трижды, каждый раз записывая отдельный объект полного набора данных:

Попытка	Преобразование, с	Пик RSS, МиБ
1	5.709	1378.9
2	5.507	1501.0
3	5.001	1617.7

Медиана преобразования — 5.507 с. Сравнила общее время n расчётов: T_CSV(n) = n × 1.083; T_Parquet(n) = 5.507 + n × 0.523. Это оценка по медианам, а не отдельные замеры длинной серии.



Преобразование учитывается один раз перед первым расчётом.

Число расчётов	CSV, с	Parquet с преобразованием, с
1	1.08	6.03
5	5.42	8.12
10	10.83	10.73
20	21.66	15.96

По этой оценке Parquet начинает выигрывать примерно с десятого повторного расчёта. Для одной задачи быстрее прочитать исходный CSV. Для серии запросов выгоднее один раз подготовить Parquet. Преобразование также заметно тяжелее по памяти, чем отдельный запрос: пик составил 1 379–1 618 МиБ.

Условия измерений

DuckDB 1.4.3, Python 3.14.4, macOS arm64, 24 ГиБ RAM. Четыре потока, одинаковые фильтр, нормализация и SQL подсчёта. Каждый запуск — новый процесс; полное время включает подключение, расчёт и запись одинаковых JSON. Форматы чередовала. Расширение httpfs установлено заранее; кэш ОС не сбрасывала.

RSS опрашивался каждые 10 мс; память RustFS не учитывалась. Короткие пики между опросами могли быть пропущены. Сравнивала один объект CSV с одним объектом Parquet. CSV оставила для проверки, поэтому уменьшение размера альтернативного формата не означает уменьшение общего объёма при хранении обеих версий.

```
python -m src.parquet_experiment run --trials 3
```

Код: src/parquet_experiment.py. Проверки и выводы: evidence/parquet/. Итоги: results/parquet/summary.json.